

Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada

Pedro Henrique Silva Da Costa Gregório
pedro.gregorio@copin.ufcg.edu.br
Universidade Federal de Campina Grande (UFCG)
Campina Grande, PB, Brasil

Resumo

A depuração de sistemas multiagentes baseados em LLMs é desafiadora devido à natureza não determinística das execuções e à diversidade de artefatos gerados ao longo das trajetórias. O AgentRx propõe um framework para diagnosticar falhas a partir dessas trajetórias, localizando a etapa crítica e classificando a causa raiz. Este trabalho realiza uma replicação controlada do AgentRx em um sistema multiagente simulado, comparando duas representações da mesma trajetória: logs textuais simplificados e telemetria estruturada inspirada em OpenTelemetry. Foram avaliados 30 cenários pareados com falhas injetadas em cinco categorias. Os resultados indicam que a telemetria estruturada não produziu ganho consistente na localização exata da etapa crítica, mas apresentou vantagem descritiva na classificação da categoria da falha. Esses achados sugerem que a estruturação da trajetória pode ser mais útil para reduzir ambiguidades semânticas em algumas categorias do que para localizar com maior precisão o passo crítico da falha.

Keywords

Sistemas Multiagentes, AgentOps, OpenTelemetry, Telemetria Estruturada, Injeção de Falhas, Diagnóstico de Falhas

ACM Reference Format:

Pedro Henrique Silva Da Costa Gregório. 2018. Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada. In *Proceedings of Make sure to enter the correct conference title from your rights confirmation email (Conference acronym 'XX)*. ACM, New York, NY, USA, 7 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 Introdução

Sistemas Multiagentes (*Multi-Agent Systems*, MAS) baseados em Grandes Modelos de Linguagem (LLMs) vêm sendo empregados em tarefas que combinam planejamento, uso de ferramentas e coordenação entre agentes. Entretanto, a natureza probabilística das execuções, a extensão dos fluxos e a diversidade dos artefatos produzidos dificultam sua observação e depuração. Nesse contexto, AgentOps propõe rastrear não apenas o resultado final, mas também o processo que o produziu, correlacionando agentes, planos,

tarefas, ferramentas e avaliações por meio de *traces*, *spans*, eventos e métricas [2]

Dentro desse cenário, o AgentRx propõe um framework de diagnóstico para localizar a primeira falha irrecuperável em trajetórias de agentes e atribuir sua causa raiz. Em sua formulação original, o método foi avaliado sobre 115 trajetórias falhas coletadas em três domínios reais e heterogêneos (*tau-bench*, *Flash* e *Magentic-One*), anotadas manualmente com a etapa crítica e a categoria da falha. O fluxo do framework normaliza os rastros em uma Representação Intermediária (IR), sintetiza restrições globais e dinâmicas, produz um log de validação auditável e utiliza um juiz baseado em LLM para inferir a etapa crítica e a categoria da falha [1].

Ainda conforme o estudo, os autores apontam que o AgentRx pode ser induzido ao erro quando os sinais de validação são fracos ou contêm falsos positivos, e indicam como trabalho futuro a identificação de conjuntos de sinais de maior qualidade, capazes de separar verdadeiros positivos de sinalizações ruidosas [1]. Se a qualidade do diagnóstico depende da qualidade dos sinais disponíveis na trajetória, então a forma como a execução é registrada e representada torna-se determinante. Grande parte dos sistemas de agentes registra sua execução por meio de logs textuais, que tendem a ser heterogêneos, incompletos ou ambíguos, exigindo etapas adicionais de normalização antes de qualquer análise. Uma representação estruturada da trajetória, por outro lado, pode tornar explícitos elementos que no texto ficam implícitos como os agentes, ações, ferramentas, eventos, status, erros e as relações hierárquicas entre operações.

Nesse ponto, o OpenTelemetry se apresenta como um candidato a fonte de sinais estruturados, por fornecer um vocabulário padronizado para representar execuções observáveis, incluindo atributos de spans, relações hierárquicas entre operações, eventos e métricas quantitativas associadas a custo, duração e uso de tokens [3].

Embora o OpenTelemetry forneça sinais estruturados sobre agentes, ferramentas, eventos, estados e relações hierárquicas, não está claro se esses sinais melhoram o diagnóstico do AgentRx em relação a representações textuais mais simples. Para investigar essa questão, este trabalho realiza uma replicação controlada em um MAS simulado, comparando, sobre os mesmos cenários pareados e com falhas injetadas, uma representação textual simplificada e uma representação com telemetria estruturada.

As questões de pesquisa que guiam este estudo são:

- **RQ1:** A telemetria estruturada melhora a identificação da etapa crítica da falha em comparação com logs textuais?
- **RQ2:** A telemetria estruturada reduz ambiguidades na categorização da causa raiz das falhas?

As questões de pesquisa foram operacionalizadas por meio de hipóteses estatísticas. Para RQ1, a hipótese nula estabelece que

não há diferença entre as representações quanto à identificação da etapa crítica. Para RQ2, a hipótese nula estabelece que não há diferença quanto à classificação da categoria da falha. As hipóteses alternativas consideram a existência de diferença entre os tratamentos.

As principais contribuições deste trabalho são: (i) uma adaptação experimental do AgentRx para um MAS simulado com falhas injetadas de categorias conhecidas; (ii) uma comparação pareada entre uma representação textual simplificada e uma representação com telemetria estruturada da mesma trajetória, ambas processadas pelo AgentRx; (iii) uma análise exploratória do efeito da representação da trajetória sobre a localização da etapa crítica e a classificação da categoria da causa raiz; e (iv) uma discussão sobre limitações e sobre quais sinais de telemetria podem apoiar diagnósticos futuros.

O restante deste trabalho está organizado da seguinte forma: a Seção 2 apresenta o AgentRx e os conceitos de telemetria estruturada; a Seção 3 descreve o desenho experimental; a Seção 4 apresenta os resultados; a Seção 5 discute os achados e os padrões de erro; a Seção 6 reúne as conclusões e os artefatos de reprodução; e a Seção 7 apresenta as ameaças à validade.

2 Fundamentação Teórica

Conforme apresentado na Seção 1, o AgentRx é um framework independente de domínio para o diagnóstico de falhas em execuções agênticas. Seu objetivo é localizar a *falha crítica*, definida como a primeira falha irreversível da trajetória, e atribuir-lhe uma categoria de causa raiz [1]. Nesta seção, são detalhados os componentes do framework relevantes para a replicação realizada neste trabalho, incluindo sua Representação Intermediária, o processo de síntese e validação de restrições e a taxonomia de falhas utilizada pelo modelo juiz.

Operacionalmente, o AgentRx recebe uma trajetória falha, os esquemas das ferramentas disponíveis e, opcionalmente, uma política de domínio em linguagem natural. Inicialmente, a trajetória é normalizada em uma Representação Intermediária (IR), permitindo o tratamento uniforme de execuções provenientes de diferentes sistemas. A partir dessa representação, o framework sintetiza restrições globais, derivadas dos esquemas das ferramentas e das políticas do domínio, e restrições dinâmicas, construídas para cada etapa com base na instrução da tarefa e no prefixo observado da trajetória. Cada restrição contém uma guarda, que determina sua aplicabilidade, e uma asserção, avaliada por verificações programáticas ou semânticas baseadas em LLM [1].

A avaliação das restrições produz um log de validação indexado por etapa, contendo as violações e suas evidências. Esse log, juntamente com a instrução, a trajetória e uma lista de verificação derivada da taxonomia, é fornecido a um juiz baseado em LLM, responsável por inferir a etapa crítica e a categoria da causa raiz [1].

Uma das contribuições do AgentRx é uma taxonomia de falhas multidomínio, obtida por um processo de codificação por *grounded theory*, no qual as categorias emergiram de padrões recorrentes de falha em vez de serem impostas a priori [1]. A taxonomia rotula a causa raiz da falha crítica e é composta por nove categorias:

- (1) **Instruction/Plan Adherence Failure:** Ocorre quando o agente não segue as diretrizes ou o plano acordado, seja por subexecução, seja pela execução de ações não previstas.
- (2) **Invention of New Information:** Ocorre quando o agente introduz, remove ou altera informação não fundamentada na entrada, no contexto ou na saída das ferramentas, incluindo fabricação de fatos e alucinações.
- (3) **Invalid Invocation:** Ocorre quando o agente emite uma chamada de ferramenta inválida, com entradas malformadas ou argumentos obrigatórios ausentes que falham na validação de esquema.
- (4) **Misinterpretation of Tool Output:** Ocorre quando o agente raciocina incorretamente sobre a saída de uma ferramenta, própria ou de outro agente.
- (5) **Intent-Plan Misalignment:** Ocorre quando o agente interpreta mal o objetivo ou as restrições do usuário e produz um plano incorreto.
- (6) **Under-specified User Intent:** Ocorre quando a tarefa não pode ser concluída por falta de informação completa.
- (7) **Intent Not Supported:** Ocorre quando se solicita uma ação para a qual não há ferramenta disponível.
- (8) **Guardrails Triggered:** Ocorre quando a execução é bloqueada por políticas de segurança ou restrições externas de acesso.
- (9) **System Failure:** Ocorre quando há uma falha de conectividade ao acionar uma ferramenta, como um *endpoint* inacessível [1].

Essas categorias oferecem um vocabulário comum para atribuição de causa raiz e são justamente o alvo de classificação inferido pelo juiz do framework [1].

2.1 Telemetria estruturada e OpenTelemetry

O OpenTelemetry é um padrão aberto e independente de fornecedor para instrumentação, coleta e exportação de dados de observabilidade em sistemas computacionais. Seu modelo organiza a execução por meio de *traces*, que representam o fluxo completo de uma operação, e de *spans*, que descrevem suas etapas individuais e as relações hierárquicas entre elas. Cada *span* pode registrar atributos, eventos, estados, duração e informações sobre erros, enquanto métricas e logs complementam a caracterização do comportamento do sistema. Essa estrutura permite correlacionar operações distribuídas e reconstruir o caminho percorrido por uma requisição ou tarefa durante sua execução [27].

Neste trabalho, esse vocabulário é empregado para representar cada trajetória do sistema multiagente simulado como uma árvore de *spans*: um *span* raiz envolve a execução completa do *workflow*, e cada agente ou ferramenta é registrado como um *span* filho, indexado pela sua etapa na trajetória. Cada *span* carrega, de forma explícita, o papel do agente e a operação realizada, as mensagens de entrada e saída, e quando aplicável para a ferramenta acionada com seus argumentos e o resultado retornado, além de métricas quantitativas de uso de *tokens* e de duração e do estado de conclusão da operação. Eventos discretos marcam transições relevantes da execução, como a delegação de uma tarefa entre agentes, o planejamento de uma chamada de ferramenta, a falha de uma dependência ou o resultado de uma etapa de validação. Dessa forma,

elementos que em um log textual permaneceriam implícitos (quem agiu sobre qual ferramenta, com que resultado, em que ponto da hierarquia e com qual estado) tornam-se campos estruturados e diretamente inspecionáveis.

3 Desenho experimental

O experimento adota um desenho fatorial completo e pareado, composto por 30 cenários avaliados nos dois níveis do fator *representação da trajetória*: telemetria estruturada e log textual simplificado. Cada combinação entre cenário e representação foi submetida a dez julgamentos independentes, totalizando 600 execuções do modelo juiz. Esse número de repetições, superior às três execuções empregadas no estudo original do AgentRx, foi adotado para caracterizar melhor a variabilidade decorrente do comportamento não determinístico do juiz e produzir estimativas agregadas mais estáveis. As variáveis dependentes consideradas foram *Critical Step Accuracy*, *Critical Step-index Accuracy*, *Average Step Distance* e *Failure Category Accuracy* (ver Seção 3.5)

3.1 Sistema multiagente simulado

O ambiente foi implementado com LangGraph como um MAS de quatro agentes: **Coordenador**, **Pesquisador**, **Executor** e **Avaliador**, que acessam uma ferramenta de catálogo *mockada* e controlada localmente. Embora sejam quatro agentes, a trajetória instrumentada registra cinco passos, pois a execução da ferramenta é capturada como um passo próprio entre o Pesquisador e o Executor. Seguindo a Figura 1, uma tarefa percorre o sistema assim: (1) a tarefa é definida e enviada ao Coordenador, que interpreta a solicitação e define, de forma determinística, a consulta e o plano, delegando-os ao Pesquisador; (2) o Pesquisador analisa as ferramentas disponíveis e prepara a chamada concreta a partir do plano; (3) a ferramenta *ProductCatalogSearch* é executada, retornando o resultado da busca no catálogo; (4) o Executor sintetiza a resposta a partir desse resultado; e (5) o Avaliador decide, deterministicamente, se há evidência suficiente da ferramenta para considerar a tarefa concluída. As decisões estruturais (plano, argumentos, veredito) são determinísticas; ao LLM cabe apenas reescrever a justificativa textual, o que mantém o comportamento estável entre execuções. O MAS é agnóstico ao modelo do agente; neste estudo, os agentes de execução foram configurados com o *Gemma 3 – 27B*. As ferramentas *mockadas* garantiram reprodutibilidade e permitiram a injeção explícita de falhas.

3.2 Geração dos cenários

Os cenários partiram dos dados de catálogo do *tau-bench*¹, o mesmo *benchmark* de fluxos de API usado no estudo original. As tarefas transacionais do *tau-bench* não foram reutilizadas: são multi-turno e alteram estado, ao passo que o MAS opera em turno único e apenas sobre leitura do catálogo. Reaproveitou-se, então, o catálogo de produtos como insumo de um gerador determinístico, que instanciou consultas de leitura e computou, a partir do próprio catálogo, a resposta correta de cada uma. Foram gerados 30 cenários, distribuídos igualmente (seis por cada categoria) entre as cinco categorias de falha consideradas (ver Seção 3.3). Cada cenário originou um

par de trajetórias que representa a mesma tarefa e a mesma falha, diferindo apenas na representação.

3.3 Injeção de falhas e *ground truth*

O AgentRx define uma taxonomia composta por nove categorias de falha. Neste estudo foram consideradas apenas cinco categorias, selecionadas por serem compatíveis com o sistema multiagente simulado e por permitirem injeção determinística e controlada de falhas. As demais categorias não foram avaliadas por dependerem de características ausentes no ambiente experimental, como intenções subespecificadas, ausência de ferramentas disponíveis ou restrições externas de execução.

As falhas foram introduzidas por operadores scriptados e determinísticos, aplicados ao passo causal de cada categoria: *Instruction/Plan Adherence Failure* no Coordenador (passo 1), *Invalid Invocation* no Pesquisador (passo 2), *System Failure* na ferramenta (passo 3), e *Misinterpretation of Tool Output* e *Invention of New Information* no Executor (passo 4). Cada cenário recebeu uma única falha, de modo que o *ground truth* foi definido operacionalmente pelo ponto de injeção e pela categoria do operador aplicado. Assim, para as métricas de acurácia da etapa crítica e da categoria, considera-se correta a identificação do passo em que a falha foi introduzida por código e da categoria correspondente. Como a injeção é controlada, esse gabarito não depende da competência do modelo do agente.

Essa definição, contudo, deve ser interpretada dentro do escopo do desenho experimental. Em sistemas multiagentes, o ponto de injeção, o primeiro desvio observável e o ponto em que a execução se torna irreversível podem não coincidir. Neste estudo, a avaliação privilegia o ponto de injeção como referência de causa controlada; portanto, quando o juiz aponta um passo posterior associado ao sintoma da falha, essa predição é contabilizada como erro de localização, ainda que possa representar uma interpretação plausível da manifestação observável.

Para mitigar ameaças à validade, o evento `fault.injected` e os atributos que revelam a categoria ou o nó injetado foram removidos das trajetórias avaliadas; o juiz não recebeu o *ground truth*; e os dois braços foram derivados do mesmo *trace* OTel bruto. Além disso, o *trace* registra contexto de execução no próprio passo da causa, como o contrato da ferramenta no Pesquisador e a consulta planejada no Coordenador, tornando *Invalid Invocation* e *Instruction/Plan Adherence Failure* observáveis no ponto em que foram introduzidas.

3.4 Representações comparadas e adaptação à IR

De cada execução coletou-se um *trace* bruto em formato OpenTelemetry (JSON), fonte única das duas representações comparadas, ambas julgadas pelo AgentRx. O **braço A (telemetria estruturada)** preserva, em cada passo, papel do agente, operação, mensagens de entrada e saída, ferramenta e argumentos quando aplicável, resultado da ferramenta, métricas de *tokens* e duração, estado de conclusão e relações hierárquicas entre *spans*. O **braço B (log textual simplificado)** descreve a mesma trajetória descritiva, sem os campos de telemetria.

¹<https://github.com/sierra-research/tau-bench>




Figura 1: Visão geral do desenho experimental proposto.

Como as duas representações são derivadas do mesmo *trace*, a comparação controla a tarefa e a falha subjacentes. O contraste avalia o efeito conjunto da estruturação e dos sinais adicionais preservados no braço de telemetria sobre o diagnóstico do AgentRx.

A derivação a partir de uma fonte comum garante que ambos os braços representem a mesma tarefa e a mesma falha, embora o braço de telemetria preserve atributos adicionais ausentes no log textual. Um adaptador converteu ambos para a IR do AgentRx; como essa IR representa cada passo por um papel e um conteúdo textual, os elementos de telemetria do braço A foram inseridos no próprio conteúdo do passo, de forma textual.

3.5 Execução do AgentRx e métricas

Utilizou-se o modelo *GPT-5.5* como juiz, listado como modelo padrão na configuração (.env) do repositório do AgentRx² via Copilot CLI. Cada trajetória foi julgada dez vezes, agregando-se por cenário a categoria pela moda e o passo pela média, conforme o estudo original [1]. Para avaliar a localização da falha, foram reproduzidas três métricas do estudo original do AgentRx para localização, utilizou-se **Critical Step Accuracy**, que mede a fração de trajetórias em que o passo crítico predito coincide exatamente com o passo anotado; **Critical Step-index Accuracy@±1**, que considera correta a predição situada até r passos do passo anotado, para $r \in \{1, 3, 5\}$; e **Average Step Distance**, que mede a distância média absoluta entre o passo predito e o passo anotado, sendo menor melhor. Para classificação, utilizou-se **Failure Category Accuracy**, isto é, a fração de trajetórias em que a categoria de falha predita coincide com a categoria anotada. No estudo original, essa métrica é reportada nas variantes crítica e *any-failure*; neste experimento, como cada cenário possui uma única falha anotada, as duas definições coincidem. Todas as comparações entre os braços A e B foram pareadas por cenário.

Tabela 1: Resumo das métricas principais no experimento MAS-SIM.

Métrica	Telemetria (A)	Log textual (B)	Δ A-B
Critical Step Accuracy	83,3%	86,7%	-3,3 p.p.
Critical Step-index Accuracy ± 1	96,7%	96,7%	,0 p.p.
Failure Category Accuracy	86,7%	80,0%	+6,7 p.p.
Average Step Distance	0,263	0,210	+0,053

4 Resultados

Esta seção apresenta os resultados do experimento MAS-SIM (agente Gemma 3-27B; juiz GPT-5.5; dez julgamentos por trajetória; comparando o braço A (telemetria estruturada) e o braço B (log textual simplificado) sobre os mesmos 30 cenários pareados. Os valores são preliminares e devem ser lidos como evidência descritiva: como mostra a análise pareada (Seção 4.4), nenhuma diferença entre os braços foi estatisticamente detectável.

4.1 Resultados agregados

A Tabela 1 apresenta as métricas principais seguindo a estrutura proposta pelos autores do AgentRx [1]. Na identificação exata da etapa crítica, o log textual simplificado obteve 86,7% de acurácia e a telemetria estruturada 83,3%, uma diferença de -3,3 pontos percentuais para a telemetria, pequena e sem vantagem prática clara. Já para o *Critical Step-index Accuracy@±1*, ambos os braços empataram em 96,7%. Na classificação da categoria da causa raiz, o comportamento se inverteu: a telemetria alcançou 86,7% contra 80,0% do log textual, uma diferença descritiva de +6,7 pontos. A distância média de passo foi ligeiramente menor no log textual (0,210 contra 0,263). Em síntese, a telemetria não produziu ganho uniforme, exibindo comportamento distinto conforme a dimensão avaliada.

²<https://github.com/microsoft/AgentRx>

Tabela 2: Estatísticas descritivas da distância de passo no experimento MAS-SIM. Valores menores indicam melhor localização da etapa crítica.

Braço	Média	DP	Med.	Mín.	Máx.	Norm.
Telemetria (A)	0,263	0,629	0	0	3	0,053
Log textual (B)	0,210	0,596	0	0	3	0,042

4.2 Localização da etapa crítica

Considerando os cenários individualmente de acordo com a Tabela 4, o log textual localizou corretamente a etapa crítica em 26 dos 30 cenários e a telemetria em 25, e as métricas de intervalo Critical Step-index Accuracy saturaram em 100% em ambos os braços (± 3 e ± 5), caracterizando um efeito-teto associado às trajetórias de apenas cinco passos. Esse desempenho global, contudo, oculta uma forte concentração dos erros. Como detalha a Tabela 4, três das cinco categorias: *System Failure*, *Misinterpretation of Tool Output* e *Invention of New Information*, foram localizadas com exatidão em todos os seis cenários (6/6) pelos dois braços, de modo que a totalidade do erro de localização se restringe a *Invalid Invocation* e *Instruction/Plan Adherence Failure*.

Tabela 3: Frequência de acertos/erros nas repetições do juiz por categoria de falha no experimento MAS-SIM.(6 cenários × 10 repetições).

Categoria	Cat. A	Cat. B	Passo A	Passo B
System Failure	60/0	60/0	60/0	60/0
Invalid Invocation	60/0	60/0	35/25	47/13
Misinterpretation of Tool Output	60/0	60/0	60/0	60/0
Invention of New Information	51/9	47/13	60/0	60/0
Instruction/Plan Adherence Failure	23/37	21/39	30/30	29/31

A leitura no nível das repetições individuais (Tabela 3; 60 julgamentos por categoria em cada braço) quantifica essa concentração e a divergência entre os braços. É em *Invalid Invocation* que eles mais se distanciam: o log textual acertou a etapa em 47 de 60 julgamentos, contra 35 de 60 da telemetria; já *Plan Adherence* colapsa para cerca de metade dos julgamentos em ambos os braços (30 e 29 acertos em 60), enquanto as três categorias restantes permanecem em 60/60. Coerentemente a distância média de passo, ligeiramente menor no log textual (0,210 contra 0,263; Tabela 2), é produzida quase inteiramente por essas duas categorias (0,417 e 0,217 em *Invalid Invocation*; 0,900 e 0,833 em *Plan Adherence*; Tabela 4), enquanto as demais contribuem com distância nula. A mediana zero e o máximo de três passos em ambos os braços, somados a um desvio-padrão da ordem da própria média (0,629 e 0,596; 2), confirmam uma distribuição fortemente assimétrica.

4.3 Classificação da categoria da causa raiz

Na classificação da categoria da causa raiz, a telemetria acertou 26 dos 30 cenários e o log textual 24. A Tabela 4 desagrega o resultado por tipo de falha: ambos os braços foram perfeitos (100,0%) em *System Failure*, *Invalid Invocation* e *Misinterpretation of Tool Output*, de modo que toda a diferença agregada provém de duas categorias

semânticas. A primeira é *Invention of New Information*, na qual a telemetria obteve 100,0% contra 66,7% do log textual; a segunda é *Instruction/Plan Adherence Failure*, a mais difícil do conjunto, com apenas 33,3% de acurácia em ambos os braços.

A Tabela 3, que reporta a frequência de acertos nas 60 repetições por categoria, matiza essa leitura e mostra que a distância entre os braços é menor do que a acurácia por cenário sugere. Em *Invention*, a telemetria classificou corretamente 51 de 60 julgamentos e o log textual 47 de 60; a diferença de 100,0% para 66,7% na acurácia por cenário não resulta, portanto, de uma falha sistemática do log textual, mas de a moda das dez repetições tombar para a categoria vizinha *Misinterpretation of Tool Output* em apenas dois cenários, ainda que a maioria das repetições continue a apontar *Invention*. Em *Plan Adherence*, ao contrário, a fragilidade é estrutural: ambos os braços acertam a categoria em menos da metade dos julgamentos (23 de 60 e 21 de 60), a única categoria cuja frequência de acerto por repetição fica abaixo de 50%. O contraste entre as duas granularidades, a moda por cenário (Tabela 4) e a frequência por repetição (Tabela 3), indica que os erros se concentram em *Invention* e, sobretudo, em *Plan Adherence*, e que parte deles reflete a instabilidade do juiz entre repetições.

4.4 Comparação pareada

Como o experimento possui desenho pareado, os dois tratamentos foram aplicados aos mesmos 30 cenários, de modo que cada cenário atua como seu próprio controle. Dessa forma, não foi necessária a alocação aleatória dos cenários entre grupos independentes. Para as métricas categóricas de acerto e erro, as comparações inferenciais foram realizadas por meio do teste de McNemar, apropriado para duas condições aplicadas aos mesmos itens e que não pressupõe normalidade dos dados. O teste concentra-se nos pares discordantes, isto é, nos cenários em que apenas um dos braços produziu a resposta correta. Sua hipótese nula estabelece a ausência de assimetria sistemática entre essas discordâncias, e não a equivalência substantiva entre os tratamentos. Conforme apresentado na Tabela 5, não foi detectada diferença estatisticamente significativa para a classificação da categoria de falha ($p = 0,617$) nem para a localização exata da etapa crítica ($p = 1,000$). Portanto, as diferenças observadas descritivamente devem ser interpretadas com cautela, especialmente em razão do número reduzido de cenários e de pares discordantes.

5 Discussão

Esta seção responde às questões de pesquisa a partir de tendências descritivas, pois os achados são preliminares e nenhuma diferença entre os braços foi estatisticamente detectável.

5.1 RQ1: a telemetria estruturada melhora a identificação da etapa crítica?

Os resultados não sustentam uma resposta afirmativa. O log textual simplificado foi ligeiramente superior à telemetria na localização exata (86,7% contra 83,3%) e na distância média de passo, com empate sob a métrica de *Critical step-index accuracy* ± 1 . Essa vantagem se concentra inteiramente de *Invalid Invocation* (Tabela 3), na qual o log textual acertou a etapa em 47 das 60 repetições contra

Tabela 4: Resultados por categoria de falha no experimento MAS-SIM.

Categoria	Braço	Failure Category Accuracy	Critical Step Accuracy	Average Step Distance
System Failure	Telemetria (A)	100,0%	6/6	0,000
System Failure	Log textual (B)	100,0%	6/6	0,000
Invalid Invocation	Telemetria (A)	100,0%	4/6	0,417
Invalid Invocation	Log textual (B)	100,0%	5/6	0,217
Misinterpretation of Tool Output	Telemetria (A)	100,0%	6/6	0,000
Misinterpretation of Tool Output	Log textual (B)	100,0%	6/6	0,000
Invention of New Information	Telemetria (A)	100,0%	6/6	0,000
Invention of New Information	Log textual (B)	66,7%	6/6	0,000
Instruction/Plan Adherence Failure	Telemetria (A)	33,3%	3/6	0,900
Instruction/Plan Adherence Failure	Log textual (B)	33,3%	3/6	0,833

Tabela 5: Teste de McNemar para as métricas categóricas pareadas no experimento MAS-SIM.

Métrica	Ambos	Só A	Só B	Nenhum	<i>p</i>
Failure Category Accuracy	23	3	1	3	0,617
Critical Step Accuracy	25	0	1	4	1,000

35 da telemetria, nas demais categorias, o desempenho foi semelhante ou idêntico. A divergência decorre de uma ambiguidade entre causa e sintoma (detalhada na Seção 5.3): ao anexar ao passo do erro (o *SchemaError*, no passo 3) atributos como *status ERROR*, tipo de exceção e *stack trace*, a telemetria torna o passo do *sintoma* mais saliente e desloca o juiz do passo da *causa* (a chamada malformada, no passo 2). Como a diferença não foi estatisticamente detectável ($p = 1,000$; Seção 4.4) e as trajetórias de cinco passos impõem um efeito-teto que limita a discriminação, conclui-se que, no formato avaliado, a telemetria estruturada **não** melhorou a identificação da etapa crítica; onde os braços divergiram, o detalhamento operacional do erro atuou, paradoxalmente, como distrator na localização fina.

5.2 RQ2: a telemetria estruturada reduz ambiguidades na categorização da causa raiz?

Há um indício descritivo, porém fraco, nesse sentido. A telemetria obteve maior acurácia de categoria, mas a diferença não foi estatisticamente detectável e concentrou-se em *Invention of New Information* (Tabela 4). A análise das repetições (Tabela 3) mostra que os os braços estão próximos, 51 de 60 julgamentos corretos na telemetria contra 47 no log textual, de modo que o salto de 66,7% para 100,0% na acurácia por cenário resulta de a moda de apenas dois cenários tombar entre *Invention* e a categoria semanticamente vizinha *Misinterpretation of Tool Output*, ambas falhas do Executor. Uma leitura plausível para a pequena vantagem da telemetria é que o registro estruturado do passo de síntese torna mais explícito que a resposta cita um item ausente da evidência da ferramenta, inclinando algumas repetições adicionais para *Invention*. Por depender de uma só categoria, de dois cenários e de uma margem de uma a

duas repetições, e por incidir sobre uma fronteira de alta instabilidade entre as reps, o achado é frágil e requer replicação.

5.3 Análise post-hoc dos erros

Além da comparação planejada, inspecionaram-se os cenários em que os braços divergiram, a fim de compreender *por que* o diagnóstico falhou. Essa análise é exploratória e post-hoc.

Em *Invalid Invocation*, o log textual localizou 5 de 6 cenários e a telemetria 4 de 6. A inspeção revela uma ambiguidade entre causa e sintoma: o juiz tende a atribuir a falha ao passo do sintoma (o *SchemaError*, no passo 3) em vez do passo da causa (a chamada malformada, no passo 2). A telemetria, por expor mais detalhes do erro lançado, parece amplificar o passo 3 como discriminador. Em um cenário de avaliação da categoria, 9 das 10 repetições do braço A migraram para o passo 3, e o cenário q10 foi errado por ambos pela mesma razão. Como causa e sintoma são passos adjacentes, o empate sob *Critical Step-index Accuracy* ± 1 mostra que se trata de ambiguidade fina, não de erro grosseiro.

A categoria *Instruction/Plan Adherence Failure* teve o pior desempenho em ambos os braços (33,3% de categoria; 3 de 6 na localização), sem que a telemetria a atenuasse. A falha é injetada no Coordenador (passo 1) como uma consulta que viola silenciosamente uma restrição da tarefa, **sem** gerar erro ou status anômalo em nenhum passo. Os erros refletem esse caráter silencioso. Nos três cenários em que a etapa crítica não foi localizada, o juiz não detectou qualquer falha em dois deles, produzindo o veredito *Inconclusive* no passo 0 em todas as repetições. No terceiro, identificou uma resposta incorreta, mas atribuiu a falha ao Executor como *Misinterpretation of Tool Output*, no passo 4; e, mesmo quando o passo 1 foi corretamente localizado (q25 e q27), a categoria oscilou entre *Instruction/Plan Adherence Failure* e a categoria vizinha *Intent-Plan Misalignment*. Esse padrão sugere que a telemetria operacional captura mal falhas que não produzem anomalias de execução, mas apenas divergências entre a intenção e o plano. Seu diagnóstico pode exigir sinais semânticos adicionais, como restrições da tarefa, sub-objetivos ativos e a relação entre as ações esperada e executada.

6 Conclusão

Este trabalho investigou, por meio de uma replicação controlada do AgentRx, se a representação de trajetórias como telemetria estruturada altera o diagnóstico de falhas em comparação com logs textuais simplificados. A avaliação utilizou 30 cenários pareados, com falhas injetadas em cinco categorias.

Os resultados são preliminares e devem ser lidos como evidência descritiva, uma vez que o teste de McNemar não detectou diferença estatisticamente significativa entre os braços em nenhuma das métricas. Quanto à **RQ1**, a telemetria estruturada não melhorou a identificação da etapa crítica, com o log textual simplificado ligeiramente superior na localização exata e na distância média. Quanto à **RQ2**, observou-se um indicio descritivo, porém fraco, de que a telemetria reduz ambiguidades na categorização da causa raiz, mas não foi estatisticamente detectável.

Além disso, estes resultados indicam que os sinais adicionais da telemetria podem produzir efeitos distintos conforme a natureza da falha: em alguns casos, tornam a categoria mais explícita; em outros, aumentam a saliência do sintoma e dificultam a identificação da causa. Assim, a utilidade da telemetria depende não apenas de sua quantidade, mas também da relação entre os sinais registrados e o alvo do diagnóstico. Sendo assim, a telemetria estruturada, no formato avaliado, não produziu ganho robusto e generalizado sobre a representação textual.

A principal implicação do estudo é que sinais operacionais, como estados, erros, duração e chamadas de ferramentas, podem ser insuficientes para falhas semânticas de *Instruction/Plan Adherence Failure*. Esse resultado motiva a investigação de uma camada de telemetria semântica que represente explicitamente objetivos, restrições e ações esperadas.

Como trabalho futuro, pretende-se ampliar o número de cenários e empregar trajetórias mais longas e complexas, capazes de mitigar o efeito-teto observado nas trajetórias curtas. Pretende-se, ainda, avaliar o método sobre logs naturais de sistemas multiagentes reais, em contraste com as representações derivadas de uma mesma fonte controlada, e investigar quais sinais específicos de telemetria contribuem para diagnósticos mais precisos.

6.1 Reprodutibilidade e artefatos

Os artefatos que sustentam as duas primeiras contribuições deste trabalho estão disponíveis no repositório público do projeto³. Esses artefatos incluem a implementação da adaptação experimental do AgentRx para o sistema multiagente simulado, bem como os cenários, *traces* e scripts utilizados na comparação pareada entre a telemetria estruturada e o log textual simplificado. Também são disponibilizados os dados brutos, os scripts de análise e as instruções para configuração e reprodução do ambiente. A versão correspondente aos resultados apresentados neste artigo está identificada pela *tag* v1.0.0, permitindo recuperar o estado exato do código, dos dados e das configurações empregadas no experimento.

³<https://github.com/Pedro-H-Gregorio/AgentRx-replication>

7 Ameaças à Validade

7.1 Validade interna

Embora as medidas descritas na Seção 3.3 reduzam o risco de vazamento do *ground truth*, o processo de geração das trajetórias, o adaptador para a IR e a configuração do juiz ainda podem influenciar os resultados.

7.2 Validade de construto

Duas limitações merecem destaque. Primeiro, os dois braços são **duas representações de uma mesma fonte controlada**: o log textual simplificado é derivado da telemetria, e não coletado de um sistema real. Portanto, o estudo compara representações alternativas da mesma trajetória, uma com telemetria estruturada e outra textual, e **não** logs naturais heterogêneos contra telemetria estruturada. Segundo, a IR do AgentRx representa cada passo apenas por papel e conteúdo textual; assim, a telemetria do braço A entra como texto, e não como campos estruturados, o que pode subaproveitar seu potencial. Além disso, o *ground truth* adota o ponto de injeção como causa, que pode não coincidir com o passo em que a execução se torna irreversível.

7.3 Validade externa

O estudo usa um MAS simulado, tarefas sintéticas, ferramentas *mockadas* e apenas 30 cenários, com trajetórias curtas (cinco passos). As trajetórias curtas produzem efeito-teto nas tolerâncias Passo ± 3 e ± 5 (100% em ambos os braços), que deixam de diferenciar os métodos. Os resultados, portanto, não se generalizam diretamente para sistemas reais. Trabalhos futuros devem empregar trajetórias mais longas e complexas, múltiplas chamadas de ferramenta, falhas recuperáveis anteriores à falha principal e erros que emergem por encadeamento.

7.4 Validade de conclusão

A amostra de 30 cenários e o pequeno número de pares discordantes limitam o teste de McNemar. Portanto, a ausência de significância estatística não demonstra equivalência entre os braços, e os resultados devem ser interpretados como evidência exploratória, indicando tendências a confirmar em estudos maiores.

Declaração de uso de inteligência artificial generativa

O ChatGPT, desenvolvido pela OpenAI, foi utilizado como apoio à revisão ortográfica, à melhoria da coesão e da clareza do texto e ao refinamento da organização do desenho experimental e de sua unidade experimental. Todas as sugestões produzidas pela ferramenta foram revisadas, adaptadas e validadas pelo autor, que assume integral responsabilidade pelo conteúdo, pelas decisões metodológicas e pelas conclusões apresentadas.

Referências

- [1] Shraddha Barke, Arnav Goyal, Alind Khare, Avaljot Singh, Suman Nath, and Chetan Bansal. 2026. AgentRx: Diagnosing AI Agent Failures from Execution Trajectories. *arXiv preprint arXiv:2602.02475* (2026).
- [2] Liming Dong, Qinghua Lu, and Liming Zhu. 2024. Agentops: Enabling observability of llm agents. *arXiv preprint arXiv:2411.05285* (2024).
- [3] IBM. 2024. O que é OpenTelemetry? <https://www.ibm.com/br-pt/topics/opentelemetry>. Acessado em: 02 jun. 2026.