

Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada

Pedro Henrique Silva Da Costa Gregório
pedro.gregorio@copin.ufcg.edu.br
Universidade Federal de Campina Grande (UFCG)
Campina Grande, PB, Brasil

Abstract

A depuração de Sistemas Multiagentes (MAS) baseados em Grandes Modelos de Linguagem (LLMs) é um desafio crítico devido à natureza probabilística, de longo horizonte e mediada por saídas ruidosas de ferramentas dessas execuções. O estudo original do AgentRx introduziu um framework automatizado promissor que localiza a etapa crítica de uma falha e categoriza sua causa raiz, mas depende de logs textuais heterogêneos e desestruturados, exigindo normalizações complexas e sujeitas a ruídos. A premissa deste estudo de replicação é verificar se a injeção de uma entrada mais estruturada, fundamentada nos padrões de observabilidade do OpenTelemetry, consegue melhorar a classificação e acurácia diagnóstica do framework. Diferente do estudo original, que amostrou logs de execuções passadas no mundo real, o processo metodológico adotado aqui baseia-se em uma experimentação laboratorial controlada. Utilizando um benchmark sintético em um ambiente MAS simulado, o experimento avalia dois cenários distintos de representação de trajetórias (logs textuais simplificados versus telemetria estruturada), visando não apenas elevar a precisão do diagnóstico, mas também viabilizar a estimativa inédita do custo operacional desperdiçado pelas falhas.

CCS Concepts

• **Do Not Use This Code → Generate the Correct Terms for Your Paper;** *Generate the Correct Terms for Your Paper;* Generate the Correct Terms for Your Paper; Generate the Correct Terms for Your Paper.

ACM Reference Format:

Pedro Henrique Silva Da Costa Gregório. 2018. Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada. In *Proceedings of Make sure to enter the correct conference title from your rights confirmation email (Conference acronym 'XX)*. ACM, New York, NY, USA, 2 pages. <https://doi.org/XXXXXXX.XXXXXXX>

1 Introdução

Os Sistemas Multiagentes (MAS) baseados em LLMs estão cada vez mais autônomos, executando tarefas complexas em ambientes do

mundo real. No entanto, a mesma autonomia que viabiliza essa produtividade torna esses sistemas extremamente difíceis de depurar. Como as trajetórias são longas e a saída das ferramentas pode ser ruidosa, pequenas falhas em uma etapa inicial podem se propagar silenciosamente até que o sistema colapse de forma irrecuperável [2].

Para solucionar o problema do diagnóstico manual — que é caro e de difícil escalabilidade [3] —, o estudo de Barke et al. propôs o *AgentRx*, um framework automatizado que identifica a etapa da primeira falha crítica (irrecuperável) e sua categoria raiz [4]. O estudo original foi conduzido extraindo logs desestruturados em texto puro de três domínios heterogêneos (como o τ -bench e o Magentic-One), necessitando de grande esforço processual para normalizar os rastros em uma Representação Intermediária (IR) a fim de que um LLM-como-Juiz avaliasse as violações [5].

Embora o AgentRx represente o estado da arte na atribuição de falhas, a sua dependência de logs textuais ambíguos o torna suscetível a falsos positivos [6]. Este estudo de replicação propõe introduzir no processo de formação de dados um modelo de telemetria nativamente estruturado, baseado nos preceitos do OpenTelemetry [7]. O OpenTelemetry é um framework de observabilidade de código aberto que padroniza a coleta de dados de telemetria (rastreamentos, métricas e logs), desvinculando as aplicações da infraestrutura de rede e garantindo informações detalhadas de causa raiz sem ambiguidades [7, 8]. Ao invés do AgentRx precisar interpretar longas mensagens de texto para deduzir um erro, o modelo de telemetria fornecerá eventos padronizados (como *timeout_detected* ou *invalid_schema*) [9], reduzindo o esforço cognitivo do LLM-Juiz e purificando a análise de causa e efeito.

Com base nesta premissa, as principais Questões de Pesquisa (RQs) que guiam este estudo são [10]:

- **RQ1:** A telemetria estruturada melhora a identificação do *critical failure step* em comparação com logs textuais?
- **RQ2:** A identificação exata da etapa crítica permite estimar com precisão o custo operacional desperdiçado (tokens, latência e tempo) após a propagação da falha?

O restante do artigo está estruturado da seguinte forma: A Seção 2 detalha a metodologia de funcionamento do AgentRx, a arquitetura da telemetria proposta e o formato de integração de dados. A Seção 3 apresenta o planejamento e o design do experimento controlado.

2 Metodologia

2.1 O Framework AgentRx

O processo de diagnóstico do AgentRx opera recebendo como entrada o esquema das ferramentas, políticas de domínio e a trajetória

Permission to make digital or hard copies of all or part of this work for personal or classroom use is granted without fee provided that copies are not made or distributed for profit or commercial advantage and that copies bear this notice and the full citation on the first page. Copyrights for components of this work owned by others than the author(s) must be honored. Abstracting with credit is permitted. To copy otherwise, or republish, to post on servers or to redistribute to lists, requires prior specific permission and/or a fee. Request permissions from permissions@acm.org.

Conference acronym 'XX, Woodstock, NY

© 2018 Copyright held by the owner/author(s). Publication rights licensed to ACM.

ACM ISBN 978-1-4503-XXXX-X/2018/06

<https://doi.org/XXXXXXX.XXXXXXX>

falha. Como as execuções possuem formatos distintos, o AgentRx primeiramente as normaliza em uma Representação Intermediária (IR) comum. A partir disso, o sistema sintetiza "Restrições Globais" (baseadas nas políticas) e "Restrições Dinâmicas" (condicionadas ao histórico da trajetória) [11]. O framework avalia essas restrições passo a passo (utilizando validações em Python e verificações semânticas via LLM) [12]. Caso uma regra seja violada, o evento é adicionado a um log de validação auditável. Por fim, um LLM-como-Juiz analisa essas violações cruzando-as com um *checklist* taxonômico de falhas para determinar o exato passo crítico e a categoria do erro [13, 14].

2.2 Ambiente Simulado e Estruturação de Dados

Diferente da abordagem original que dependia de benchmarks de terceiros, a metodologia desta replicação baseia-se na construção de uma Prova de Conceito (PoC) implementada com o framework LangGraph. A unidade geradora de dados é um MAS contendo quatro agentes: Coordenador, Pesquisador, Executor e Avaliador [15].

A grande alteração metodológica é a instrumentação nativa com os conceitos do *OpenTelemetry*. Os logs gerados seguirão a seguinte padronização [9, 16, 17]:

- **Trace:** Representa a trajetória completa da tarefa (ex: *trace_id*, *start_time*, *status*).
- **Spans:** Segmentos detalhados que formam o Trace, como *Workflow Span* (fluxo principal), *Agent Span* (execução de um agente isolado) e *Tool Span* (chamada de ferramenta, evidenciando *tool_input* e *tool_output*). A relação entre Spans (*parent_span_id*) preserva a hierarquia da execução.
- **Events & Attributes:** Disparam gatilhos específicos como *timeout_detected* e injetam atributos de falha reais (*error.type*, *error.message*).
- **Metrics:** Indicadores quantitativos de custos (como *tokens_in*, *tokens_out*, *latency_ms* e *retry_count*).

2.3 Adaptação ao Fluxo do AgentRx

Para integrar nosso modelo à arquitetura metodológica do artigo base, desenvolvemos um adaptador (*Adapter*) de telemetria. Este componente é encarregado de traduzir a árvore de Traces e Spans rigorosamente para a *Trajectory IR* esperada pelo pipeline original do AgentRx. Graças à formatação estruturada na origem, o gerador de restrições dinâmicas do AgentRx será reconfigurado para ler gatilhos explícitos diretamente no JSON de telemetria em vez de precisar realizar interpretações textuais extensivas [18].

3 Análise de Experimento

3.1 Design de Experimentos

O objetivo central do experimento é avaliar estatisticamente as relações de causa e efeito das representações de log no desempenho diagnóstico do framework. Baseado nos princípios de experimentação quantitativa para analisar inferências estatísticas e mitigar vieses [19], definimos um desenho de experimento **fatorial completo** 2×5 [20, 21].

Variável Independente (Fator): O experimento avalia dois níveis de representação da trajetória:

- (1) *Logs textuais simplificados (Baseline)*: Simula a representação original, extraindo a trajetória textualmente e ocultando indicadores estruturados das métricas do OpenTelemetry.
- (2) *Telemetria Estruturada (Tratamento)*: Dados complexos contendo os Spans, Eventos e atributos predefinidos pelo nosso modelo [10].

Para o controle experimental, utilizamos a técnica de injeção de falhas. Foram selecionados 5 níveis de categorias da taxonomia original do AgentRx [21]: *System Failure*, *Invalid Invocation*, *Instruction/Plan Adherence Failure*, *Tool Misuse* (uso incorreto de ferramentas) e *Validation Failure*.

Variáveis Dependentes: As métricas utilizadas para medir o efeito dos tratamentos serão [10]:

- (1) **Critical Step Accuracy:** Percentual de precisão na identificação do índice da etapa exata do erro.
- (2) **Failure Category Accuracy:** Precisão na classificação da categoria raiz.
- (3) **Average Step Distance:** Distância média, em passos, entre a predição do modelo e o erro real.
- (4) **Custo Operacional Desperdiçado:** Calculado com base nas métricas de tokens e latência pós-falha a partir do marco crítico estabelecido pelo AgentRx.

3.2 Execução e Análise Estatística

Para garantir relevância e balanceamento [22], cada combinação do desenho fatorial gerará 5 trajetórias simuladas independentes, resultando em 50 execuções. Para mitigar o não-determinismo inerente às avaliações de LLM, a ferramenta do AgentRx julgará cada trajetória 3 vezes [23]. O *ground truth* de avaliação será extraído diretamente pelo operador de injeção de falha que gerou o respectivo problema [18].

As análises estatísticas utilizarão o cálculo de Média e Desvio Padrão para os resultados globais. Para validar a hipótese nula (H_0) — de que não há diferença de precisão entre os formatos de log —, aplicaremos inicialmente o Teste de normalidade de *Shapiro-Wilk*. Considerando amostras dependentes executadas sob a mesma base, o contraste de hipótese será aferido via teste de *Wilcoxon* pareado, adotando um nível de significância de $\alpha = 0.05$ [18].

Received 20 February 2007; revised 12 March 2009; accepted 5 June 2009