

# Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada

Pedro Henrique Silva Da Costa Gregório  
pedro.gregorio@copin.ufcg.edu.br  
Universidade Federal de Campina Grande (UFCG)  
Campina Grande, PB, Brasil

## Resumo

A depuração de sistemas multiagentes baseados em LLMs é desafiadora devido à natureza não determinística das execuções e à diversidade de artefatos gerados ao longo das trajetórias. O AgentRx propõe um framework para diagnosticar falhas a partir dessas trajetórias, localizando a etapa crítica e classificando a causa raiz. Este trabalho realiza uma replicação controlada do AgentRx em um sistema multiagente simulado, comparando duas representações da mesma trajetória: logs textuais simplificados e telemetria estruturada inspirada em OpenTelemetry. Foram avaliados 30 cenários pareados com falhas injetadas em cinco categorias. Os resultados indicam que a telemetria estruturada não produziu ganho consistente na localização exata da etapa crítica, mas apresentou vantagem descritiva na classificação da categoria da falha. Esses achados sugerem que a estruturação da trajetória pode ser mais útil para reduzir ambiguidades semânticas em algumas categorias do que para localizar com maior precisão o passo crítico da falha.

## Keywords

Sistemas Multiagentes, AgentOps, OpenTelemetry, Telemetria Estruturada, Injeção de Falhas, Diagnóstico de Falhas

## ACM Reference Format:

Pedro Henrique Silva Da Costa Gregório. 2018. Replicação AgentRx: Diagnóstico em Falhas de Sistemas Multiagentes utilizando Telemetria Estruturada. In *Proceedings of Make sure to enter the correct conference title from your rights confirmation email (Conference acronym 'XX)*. ACM, New York, NY, USA, 7 pages. <https://doi.org/XXXXXXX.XXXXXXX>

## 1 Introdução

Sistemas Multiagentes (*Multi Agent systems*, MAS) baseados em Grandes Modelos de Linguagem (LLMs) vêm sendo empregados em tarefas cada vez mais complexas, combinando planejamento, uso de ferramentas e coordenação entre agentes. Essa autonomia, embora benéfica do ponto de vista funcional, amplia a dificuldade de observação e depuração, pois as execuções são probabilísticas, os fluxos são longos e os artefatos gerados ao longo da trajetória

são variados [2]. Nesse contexto, AgentOps surge como um paradigma de observabilidade voltado a rastrear, correlacionar e analisar os artefatos produzidos por agentes ao longo de seu ciclo de vida, incluindo agente, plano, workflow, tarefa, ferramenta, avaliação e guardrails [2].

Os artigos recentes tem mostrado que a observabilidade de agentes não deve se limitar ao resultado final da tarefa, mas também ao processo de execução que leva a esse resultado. O estudo de Dong et al. [2] destaca que agentes de IA produzem artefatos complexos em diferentes camadas, e que esses artefatos devem ser rastreados por meio de traces, spans, eventos e métricas para permitir diagnóstico e responsabilização.

Dentro desse cenário, o AgentRx propõe um framework de diagnóstico para localizar a primeira falha irreversível em trajetórias de agentes e atribuir sua causa raiz. Em sua formulação original, o método foi avaliado sobre 115 trajetórias falhas coletadas em três domínios reais e heterogêneos (*tau-bench*, *Flash* e *Magentic-One*), anotadas manualmente com a etapa crítica e a categoria da falha [1]. O fluxo do framework normaliza os rastros em uma Representação Intermediária (IR), sintetiza restrições globais e dinâmicas, produz um log de validação auditável e utiliza um juiz baseado em LLM para inferir a etapa crítica e a categoria da falha [1].

Ainda conforme o estudo, os autores apontam que o AgentRx pode ser induzido ao erro quando os sinais de validação são fracos ou contêm falsos positivos, e indicam como trabalho futuro a identificação de conjuntos de sinais de maior qualidade, capazes de separar verdadeiros positivos de sinalizações ruidosas [1]. Se a qualidade do diagnóstico depende da qualidade dos sinais disponíveis na trajetória, então a forma como a execução é registrada e representada torna-se determinante. Grande parte dos sistemas de agentes registra sua execução por meio de logs textuais, que tendem a ser heterogêneos, incompletos ou ambíguos, exigindo etapas adicionais de normalização antes de qualquer análise. Uma representação estruturada da trajetória, por outro lado, pode tornar explícitos elementos que no texto ficam implícitos como os agentes, ações, ferramentas, eventos, status, erros e as relações hierárquicas entre operações.

Nesse ponto, o OpenTelemetry se apresenta como um candidato a fonte de sinais estruturados, por fornecer um vocabulário padronizado para representar execuções observáveis, incluindo atributos de spans, relações hierárquicas entre operações, eventos e métricas quantitativas associadas a custo, duração e uso de tokens [3]. Não está claro, entretanto, se essa estruturação de fato melhora o diagnóstico produzido pelo AgentRx frente a representações textuais mais simples: é possível que os sinais estruturados reduzam a ambiguidade, mas também que apenas acrescentem informação que o

juiz não aproveita. Investigar essa questão de forma controlada é o objetivo deste trabalho.

Para isso, este estudo realiza uma replicação controlada do AgentRx em um ambiente simulado de Sistemas Multiagentes, no qual as trajetórias são geradas experimentalmente e representadas de duas formas alternativas: logs textuais simplificados e telemetria estruturada inspirada em OpenTelemetry. Sobre os mesmos cenários preparados, com falhas injetadas de categorias conhecidas, comparam-se as duas representações para examinar tanto a replicabilidade do diagnóstico em um novo contexto quanto o efeito da estruturação dos registros sobre a atribuição de falhas.

As questões de pesquisa que guiam este estudo são:

- **RQ1:** A telemetria estruturada melhora a identificação da etapa crítica da falha em comparação com logs textuais?
- **RQ2:** A telemetria estruturada reduz ambiguidades na categorização da causa raiz das falhas?

As principais contribuições deste trabalho são: (i) uma adaptação experimental do AgentRx para um MAS simulado com falhas injetadas de categorias conhecidas; (ii) uma comparação pareada entre uma representação textual simplificada e uma representação com telemetria estruturada da mesma trajetória, ambas processadas pelo AgentRx; (iii) uma análise exploratória do efeito da representação da trajetória sobre a localização da etapa crítica e a classificação da categoria da causa raiz; e (iv) uma discussão sobre limitações e sobre quais sinais de telemetria podem apoiar diagnósticos futuros.

Neste contexto, este trabalho está organizado seguindo a estrutura: A Seção 2 apresenta o AgentRx, o modelo de telemetria proposto e a integração entre ambos. A Seção 3 descreve o desenho experimental, a instrumentação, as métricas e a análise estatística planejada.

## 2 Fundamentação Teórica

O AgentRx é um framework automatizado e independente de domínio para diagnóstico de execuções agênticas. Seu objetivo é localizar a *falha crítica*, definida como a primeira falha irrecuperável ao longo da trajetória, e atribuir sua causa raiz [1]. A proposta responde à dificuldade de depurar sistemas agênticos, nos quais execuções probabilísticas, longas, multiagente e dependentes de ferramentas podem fazer com que erros se propaguem antes de se tornarem observáveis [1]. Para avaliar o método, os autores construíram um *benchmark* com 115 trajetórias falhas, anotadas manualmente com etapa crítica e categoria de falha, provenientes de três domínios: fluxos de API estruturados (*tau-bench*), gerenciamento de incidentes (*Flash*) e tarefas abertas envolvendo web e arquivos (*Magentic-One*) [1].

Operacionalmente, o AgentRx recebe uma trajetória falha, um conjunto de ferramentas com seus esquemas de entrada e saída e, opcionalmente, uma política de domínio em linguagem natural. Como os formatos de execução variam entre domínios, a trajetória é primeiro normalizada em uma Representação Intermediária (IR) comum [1]. Em seguida, o framework sintetiza restrições em dois níveis: restrições globais, derivadas do esquema das ferramentas e da política de domínio, e restrições dinâmicas, geradas a cada etapa a partir da instrução da tarefa e do prefixo da trajetória observado até aquele ponto. Cada restrição combina uma guarda, que

define quando ela se aplica, e uma asserção, que produz um veredito binário por meio de verificações programáticas ou semânticas avaliadas por LLM [1].

A avaliação das restrições produz um log de validação indexado por etapa, que registra cada restrição violada e sua evidência de suporte [1]. Esse log, juntamente com a instrução da tarefa, a trajetória e uma lista de verificação (*checklist*) semântica derivada da taxonomia, é fornecido a um juiz baseado em LLM, que infere a etapa crítica e a categoria da falha [1]. Segundo os autores, esse acoplamento entre síntese de restrições e adjudicação por LLM apoiada em evidências melhora a localização da etapa e a atribuição da causa raiz em relação a linhas de base existentes nos três domínios avaliados [1].

Uma das contribuições do AgentRx é uma taxonomia de falhas multidomínio, obtida por um processo de codificação por *grounded theory*, no qual as categorias emergiram de padrões recorrentes de falha em vez de serem impostas a priori [1]. A taxonomia rotula a causa raiz da falha crítica e é composta por nove categorias:

- (1) **Instruction/Plan Adherence Failure:** Ocorre quando o agente não segue as diretrizes ou o plano acordado, seja por subexecução, seja pela execução de ações não previstas.
- (2) **Invention of New Information:** Ocorre quando o agente introduz, remove ou altera informação não fundamentada na entrada, no contexto ou na saída das ferramentas, incluindo fabricação de fatos e alucinações.
- (3) **Invalid Invocation:** Ocorre quando o agente emite uma chamada de ferramenta inválida, com entradas malformadas ou argumentos obrigatórios ausentes que falham na validação de esquema.
- (4) **Misinterpretation of Tool Output:** Ocorre quando o agente raciocina incorretamente sobre a saída de uma ferramenta, própria ou de outro agente.
- (5) **Intent-Plan Misalignment:** Ocorre quando o agente interpreta mal o objetivo ou as restrições do usuário e produz um plano incorreto.
- (6) **Under-specified User Intent:** Ocorre quando a tarefa não pode ser concluída por falta de informação completa.
- (7) **Intent Not Supported:** Ocorre quando se solicita uma ação para a qual não há ferramenta disponível.
- (8) **Guardrails Triggered:** Ocorre quando a execução é bloqueada por políticas de segurança ou restrições externas de acesso.
- (9) **System Failure:** Ocorre quando há uma falha de conectividade ao acionar uma ferramenta, como um *endpoint* inacessível [1].

Essas categorias oferecem um vocabulário comum para atribuição de causa raiz e são justamente o alvo de classificação inferido pelo juiz do framework [1].

### 2.1 Telemetria estruturada e OpenTelemetry

A qualidade do diagnóstico produzido pelo AgentRx depende dos sinais disponíveis na trajetória, e os próprios autores apontam como trabalho futuro a busca por sinais de maior qualidade, capazes de separar verdadeiros positivos de sinalizações ruidosas [1]. Grande parte dos sistemas de agentes registra sua execução por meio de

logs textuais, que tendem a ser heterogêneos e a exigir normalização antes de qualquer análise. A observabilidade de agentes, por sua vez, propõe que a execução seja registrada de forma estruturada, por meio de *traces*, *spans*, eventos e métricas, de modo a viabilizar diagnóstico e responsabilização [2]. Nesse cenário, o OpenTelemetry oferece um vocabulário padronizado para representar execuções observáveis, incluindo atributos de *spans*, relações hierárquicas entre operações, eventos e métricas quantitativas associadas a custo, duração e uso de *tokens* [3].

Neste trabalho, esse vocabulário é empregado para representar cada trajetória do sistema multiagente simulado como uma árvore de *spans*: um *span* raiz envolve a execução completa do *workflow*, e cada agente ou ferramenta é registrado como um *span* filho, indexado pela sua etapa na trajetória. Cada *span* carrega, de forma explícita, o papel do agente e a operação realizada, as mensagens de entrada e saída, e quando aplicável para a ferramenta acionada com seus argumentos e o resultado retornado, além de métricas quantitativas de uso de *tokens* e de duração e do estado de conclusão da operação. Eventos discretos marcam transições relevantes da execução, como a delegação de uma tarefa entre agentes, o planejamento de uma chamada de ferramenta, a falha de uma dependência ou o resultado de uma etapa de validação. Dessa forma, elementos que em um log textual permaneceriam implícitos (quem agiu sobre qual ferramenta, com que resultado, em que ponto da hierarquia e com qual estado) tornam-se campos estruturados e diretamente inspecionáveis.

## 3 Desenho experimental

### 3.1 Sistema multiagente simulado

O ambiente foi implementado com LangGraph como um MAS de quatro agentes: **Coordenador**, **Pesquisador**, **Executor** e **Avaliador**, que acessam uma ferramenta de catálogo *mockada* e controlada localmente. Embora sejam quatro agentes, a trajetória instrumentada registra cinco passos, pois a execução da ferramenta é capturada como um passo próprio entre o Pesquisador e o Executor. Seguindo a Figura 1, uma tarefa percorre o sistema assim: (1) a tarefa é definida e enviada ao Coordenador, que interpreta a solicitação e define, de forma determinística, a consulta e o plano, delegando-os ao Pesquisador; (2) o Pesquisador analisa as ferramentas disponíveis e prepara a chamada concreta a partir do plano; (3) a ferramenta *ProductCatalogSearch* é executada, retornando o resultado da busca no catálogo; (4) o Executor sintetiza a resposta a partir desse resultado; e (5) o Avaliador decide, deterministicamente, se há evidência suficiente da ferramenta para considerar a tarefa concluída. As decisões estruturais (plano, argumentos, veredito) são determinísticas; ao LLM cabe apenas reescrever a justificativa textual, o que mantém o comportamento estável entre execuções. O MAS é agnóstico ao modelo do agente; neste estudo, os agentes de execução foram configurados com o *Gemma 3 – 27B*. As ferramentas *mockadas* garantiram reprodutibilidade e permitiram a injeção explícita de falhas.

### 3.2 Geração dos cenários

Os cenários partiram dos dados de catálogo do *tau-bench*<sup>1</sup>, o mesmo *benchmark* de fluxos de API usado no estudo original. As tarefas transacionais do *tau-bench* não foram reutilizadas: são multi-turno e alteram estado, ao passo que o MAS opera em turno único e apenas sobre leitura do catálogo. Reaproveitou-se, então, o catálogo de produtos como insumo de um gerador determinístico, que instanciou consultas de leitura e computou, a partir do próprio catálogo, a resposta correta de cada uma. Foram gerados 30 cenários, distribuídos igualmente (seis por cada categoria) entre as cinco categorias de falha consideradas. Cada cenário originou um par de trajetórias que representa a mesma tarefa e a mesma falha, diferindo apenas na representação.

### 3.3 Injeção de falhas e *ground truth*

As falhas foram introduzidas por operadores scriptados e determinísticos, aplicados ao passo causal de cada categoria: *Instruction/Plan Adherence Failure* no Coordenador (passo 1), *Invalid Invocation* no Pesquisador (passo 2), *System Failure* na ferramenta (passo 3), e *Misinterpretation of Tool Output* e *Invention of New Information* no Executor (passo 4). Cada cenário recebeu uma única falha, de modo que o *ground truth* foi definido operacionalmente pelo ponto de injeção e pela categoria do operador aplicado. Assim, para as métricas de acurácia da etapa crítica e da categoria, considera-se correta a identificação do passo em que a falha foi introduzida por código e da categoria correspondente. Como a injeção é controlada, esse gabarito não depende da competência do modelo do agente.

Essa definição, contudo, deve ser interpretada dentro do escopo do desenho experimental. Em sistemas multiagentes, o ponto de injeção, o primeiro desvio observável e o ponto em que a execução se torna irrecuperável podem não coincidir. Neste estudo, a avaliação privilegia o ponto de injeção como referência de causa controlada; portanto, quando o juiz aponta um passo posterior associado ao sintoma da falha, essa predição é contabilizada como erro de localização, ainda que possa representar uma interpretação plausível da manifestação observável.

Para mitigar ameaças à validade, o evento *fault injected* e os atributos que revelam a categoria ou o nó injetado foram removidos das trajetórias avaliadas; o juiz não recebeu o *ground truth*; e os dois braços foram derivados do mesmo *trace* OTel bruto. Além disso, o *trace* registra contexto de execução no próprio passo da causa, como o contrato da ferramenta no Pesquisador e a consulta planejada no Coordenador, tornando *Invalid Invocation* e *Instruction/Plan Adherence Failure* observáveis no ponto em que foram introduzidas.

### 3.4 Representações comparadas e adaptação à IR

De cada execução coletou-se um *trace* bruto em formato OpenTelemetry (JSON), fonte única das duas representações comparadas,

<sup>1</sup><https://github.com/sierra-research/tau-bench>




Figura 1: Visão geral do desenho experimental proposto.

ambas julgadas pelo AgentRx. O **braço A (telemetria estruturada)** preserva, em cada passo, papel do agente, operação, mensagens de entrada e saída, ferramenta e argumentos quando aplicável, resultado da ferramenta, métricas de *tokens* e duração, estado de conclusão e relações hierárquicas entre *spans*. O **braço B (log textual simplificado)** descreve a mesma trajetória descritiva, sem os campos de telemetria. Como os dois braços carregam o mesmo conteúdo semântico e diferem apenas na telemetria, a comparação isola o efeito da representação. Um adaptador converteu ambos para a IR do AgentRx; como essa IR representa cada passo por um papel e um conteúdo textual, os elementos de telemetria do braço A foram inseridos no próprio conteúdo do passo, de forma textual.

### 3.5 Execução do AgentRx e métricas

Utilizou-se o modelo *GPT-5.5* como juiz, listado como modelo padrão na configuração (.env) do repositório do AgentRx<sup>2</sup> via Copilot CLI. Cada trajetória foi julgada dez vezes, agregando-se por cenário a categoria pela moda e o passo pela média, conforme o estudo original [1]. As métricas reproduzidas do estudo original do AgentRx para localização, utilizou-se **Critical Step Accuracy**, que mede a fração de trajetórias em que o passo crítico predito coincide exatamente com o passo anotado; **Critical Step-index Accuracy@±1**, que considera correta a predição situada até  $r$  passos do passo anotado, para  $r \in \{1, 3, 5\}$ ; e **Average Step Distance**, que mede a distância média absoluta entre o passo predito e o passo anotado, sendo menor melhor. Para classificação, utilizou-se **Failure Category Accuracy**, isto é, a fração de trajetórias em que a categoria de falha predita coincide com a categoria anotada. No estudo original, essa métrica é reportada nas variantes crítica e *any-failure*; neste experimento, como cada cenário possui uma única falha anotada, as duas definições coincidem. Todas as comparações entre os braços A e B foram pareadas por cenário.

Tabela 1: Resumo das métricas principais no experimento MAS-SIM.

| Métrica                              | Telemetria (A) | Log textual (B) | $\Delta$ A–B |
|--------------------------------------|----------------|-----------------|--------------|
| Critical Step Accuracy               | 83,3%          | 86,7%           | −3,3 p.p.    |
| Critical Step-index Accuracy $\pm 1$ | 96,7%          | 96,7%           | ,0 p.p.      |
| Failure Category Accuracy            | 86,7%          | 80,0%           | +6,7 p.p.    |
| Average Step Distance                | 0,263          | 0,210           | +0,053       |

## 4 Resultados

Esta seção apresenta os resultados do experimento MAS-SIM (agente Gemma 3–27B; juiz GPT-5.5; dez julgamentos por trajetória; comparando o braço A (telemetria estruturada) e o braço B (log textual simplificado) sobre os mesmos 30 cenários pareados. Os valores são preliminares e devem ser lidos como evidência descritiva: como mostra a análise pareada (Seção 4.4), nenhuma diferença entre os braços foi estatisticamente detectável.

### 4.1 Resultados agregados

A Tabela 1 apresenta as métricas principais seguindo a estrutura proposta pelo autores do AgentRx [1]. Na identificação exata da etapa crítica, o log textual simplificado obteve 86,7% de acurácia e a telemetria estruturada 83,3%, uma diferença de −3,3 pontos percentuais para a telemetria, pequena e sem vantagem prática clara. Já para o *Critical Step-index Accuracy@±1*, ambos os braços empataram em 96,7%. Na classificação da categoria da causa raiz, o comportamento se inverteu: a telemetria alcançou 86,7% contra 80,0% do log textual, uma diferença descritiva de +6,7 pontos. A distância média de passo foi ligeiramente menor no log textual (0,210 contra 0,263). Em síntese, a telemetria não produziu ganho uniforme, exibindo comportamento distinto conforme a dimensão avaliada.

<sup>2</sup><https://github.com/microsoft/AgentRx>

**Tabela 2: Estatísticas descritivas da distância de passo no experimento MAS-SIM. Valores menores indicam melhor localização da etapa crítica.**

| Braço           | Média | DP    | Med. | Mín. | Máx. | Norm. | MAE   |
|-----------------|-------|-------|------|------|------|-------|-------|
| Telemetria (A)  | 0,263 | 0,629 | 0    | 0    | 3    | 0,053 | 0,263 |
| Log textual (B) | 0,210 | 0,596 | 0    | 0    | 3    | 0,042 | 0,237 |

## 4.2 Localização da etapa crítica

Considerando os cenários individualmente de acordo com a Tabela 4, o log textual localizou corretamente a etapa crítica em 26 dos 30 cenários e a telemetria em 25, e as métricas de intervalo Critical Step-index Accuracy saturaram em 100% em ambos os braços ( $\pm 3$  e  $\pm 5$ ), caracterizando um efeito-teto associado às trajetórias de apenas cinco passos. Esse desempenho global, contudo, oculta uma forte concentração dos erros. Como detalha a Tabela 4, três das cinco categorias: *System Failure*, *Misinterpretation of Tool Output* e *Invention of New Information*, foram localizadas com exatidão em todos os seis cenários (6/6) pelos dois braços, de modo que a totalidade do erro de localização se restringe a *Invalid Invocation* e *Instruction/Plan Adherence Failure*.

**Tabela 3: Frequência de acertos/erros nas repetições do juiz por categoria de falha no experimento MAS-SIM.(6 cenários × 10 repetições).**

| Categoria                          | Cat. A | Cat. B | Passo A | Passo B |
|------------------------------------|--------|--------|---------|---------|
| System Failure                     | 60/0   | 60/0   | 60/0    | 60/0    |
| Invalid Invocation                 | 60/0   | 60/0   | 35/25   | 47/13   |
| Misinterpretation of Tool Output   | 60/0   | 60/0   | 60/0    | 60/0    |
| Invention of New Information       | 51/9   | 47/13  | 60/0    | 60/0    |
| Instruction/Plan Adherence Failure | 23/37  | 21/39  | 30/30   | 29/31   |

A leitura no nível das repetições individuais (Tabela 3; 60 julgamentos por categoria em cada braço) quantifica essa concentração e a divergência entre os braços. É em *Invalid Invocation* que eles mais se distanciam: o log textual acertou a etapa em 47 de 60 julgamentos, contra 35 de 60 da telemetria; já *Plan Adherence* colapsa para cerca de metade dos julgamentos em ambos os braços (30 e 29 acertos em 60), enquanto as três categorias restantes permanecem em 60/60. Coerentemente, a distância média de passo, ligeiramente menor no log textual (0,210 contra 0,263; Tabela 2), é produzida quase inteiramente por essas duas categorias (0,417 e 0,217 em *Invalid Invocation*; 0,900 e 0,833 em *Plan Adherence*; Tabela 4), enquanto as demais contribuem com distância nula. A mediana zero e o máximo de três passos em ambos os braços, somados a um desvio-padrão da ordem da própria média (0,629 e 0,596; 2), confirmam uma distribuição fortemente assimétrica.

## 4.3 Classificação da categoria da causa raiz

Na classificação da categoria da causa raiz, a telemetria acertou 26 dos 30 cenários e o log textual 24. A Tabela 4 desagrega o resultado por tipo de falha: ambos os braços foram perfeitos (100,0%) em *System Failure*, *Invalid Invocation* e *Misinterpretation of Tool Output*, de modo que toda a diferença agregada provém de duas categorias semânticas. A primeira é *Invention of New Information*, na qual a

telemetria obteve 100,0% contra 66,7% do log textual; a segunda é *Instruction/Plan Adherence Failure*, a mais difícil do conjunto, com apenas 33,3% de acurácia em ambos os braços.

A Tabela 3, que reporta a frequência de acertos nas 60 repetições por categoria, matiza essa leitura e mostra que a distância entre os braços é menor do que a acurácia por cenário sugere. Em *Invention*, a telemetria classificou corretamente 51 de 60 julgamentos e o log textual 47 de 60; a diferença de 100,0% para 66,7% na acurácia por cenário não resulta, portanto, de uma falha sistemática do log textual, mas de a moda das dez repetições tombou para a categoria vizinha *Misinterpretation of Tool Output* em apenas dois cenários, ainda que a maioria das repetições continue a apontar *Invention*. Em *Plan Adherence*, ao contrário, a fragilidade é estrutural: ambos os braços acertam a categoria em menos da metade dos julgamentos (23 de 60 e 21 de 60), a única categoria cuja frequência de acerto por repetição fica abaixo de 50%. O contraste entre as duas granularidades, a moda por cenário (Tabela 4) e a frequência por repetição (Tabela 3), indica que os erros se concentram em *Invention* e, sobretudo, em *Plan Adherence*, e que parte deles reflete a instabilidade do juiz entre repetições.

## 4.4 Comparação pareada

Como cada cenário foi avaliado nos dois braços, a comparação é pareada e não envolve amostras independentes. Para as métricas categóricas de acerto/erro, utilizou-se o teste de McNemar por ser apropriado para comparar duas condições aplicadas aos mesmos itens, concentrando-se nos casos discordantes em que um braço acerta e o outro erra. A hipótese nula é a ausência de assimetria sistemática nessas discordâncias, e não uma equivalência substantiva entre os braços. A Tabela 5 mostra que não houve diferença estatisticamente detectável nem para a classificação da categoria ( $p = 0,617$ ) nem para a localização exata da etapa crítica ( $p = 1,000$ ). Assim, as diferenças descritivas devem ser lidas com cautela, dado o tamanho reduzido da amostra e o baixo número de pares discordantes.

## 5 Discussão

A discussão retoma as questões de pesquisa formuladas na introdução. Reitera-se que os achados são preliminares: como nenhuma diferença foi estatisticamente detectável (Seção 4.4), as respostas a seguir descrevem tendências, não vantagens estabelecidas.

### 5.1 RQ1: a telemetria estruturada melhora a identificação da etapa crítica?

Os resultados não sustentam uma resposta afirmativa. O log textual simplificado foi ligeiramente superior à telemetria na localização exata (86,7% contra 83,3%) e na distância média de passo (0,210 contra 0,263; Tabela 2), com empate sob tolerância de um passo (96,7%). Essa pequena vantagem, contudo, não é uniforme entre as categorias: como mostra a Tabela 3, ela se origina quase inteiramente de *Invalid Invocation*, na qual o log textual acertou a etapa em 47 das 60 repetições contra 35 da telemetria, enquanto nas demais categorias os braços são idênticos. A divergência decorre de uma ambiguidade entre causa e sintoma (detalhada na Seção 5.3): ao anexar ao passo do erro (o *SchemaError*, no passo 3) atributos como *status ERROR*, tipo de exceção e *stack trace*, a telemetria torna o passo do *sintoma* mais saliente e desloca o juiz do passo da *causa*

**Tabela 4: Resultados por categoria de falha no experimento MAS-SIM.**

| Categoria                          | Braço           | Failure Category Accuracy | Critical Step Accuracy | Average Step Distance |
|------------------------------------|-----------------|---------------------------|------------------------|-----------------------|
| System Failure                     | Telemetria (A)  | 100,0%                    | 6/6                    | 0,000                 |
| System Failure                     | Log textual (B) | 100,0%                    | 6/6                    | 0,000                 |
| Invalid Invocation                 | Telemetria (A)  | 100,0%                    | 4/6                    | 0,417                 |
| Invalid Invocation                 | Log textual (B) | 100,0%                    | 5/6                    | 0,217                 |
| Misinterpretation of Tool Output   | Telemetria (A)  | 100,0%                    | 6/6                    | 0,000                 |
| Misinterpretation of Tool Output   | Log textual (B) | 100,0%                    | 6/6                    | 0,000                 |
| Invention of New Information       | Telemetria (A)  | 100,0%                    | 6/6                    | 0,000                 |
| Invention of New Information       | Log textual (B) | 66,7%                     | 6/6                    | 0,000                 |
| Instruction/Plan Adherence Failure | Telemetria (A)  | 33,3%                     | 3/6                    | 0,900                 |
| Instruction/Plan Adherence Failure | Log textual (B) | 33,3%                     | 3/6                    | 0,833                 |

**Tabela 5: Teste de McNemar para as métricas categóricas pareadas no experimento MAS-SIM.**

| Métrica                   | Ambos | Só A | Só B | Nenhum | <i>p</i> |
|---------------------------|-------|------|------|--------|----------|
| Failure Category Accuracy | 23    | 3    | 1    | 3      | 0,617    |
| Critical Step Accuracy    | 25    | 0    | 1    | 4      | 1,000    |

(a chamada malformada, no passo 2). Como a diferença não foi estatisticamente detectável ( $p = 1,000$ ; Seção 4.4) e as trajetórias de cinco passos impõem um efeito-teto que limita a discriminação, conclui-se que, no formato avaliado, a telemetria estruturada **não** melhorou a identificação da etapa crítica; onde os braços divergiram, o detalhamento operacional do erro atuou, paradoxalmente, como distrator na localização fina.

## 5.2 RQ2: a telemetria estruturada reduz ambiguidades na categorização da causa raiz?

Há indício descritivo nesse sentido, porém fraco. A telemetria obteve maior acurácia de categoria (86,7% contra 80,0%; Tabela 1), mas a diferença não foi estatisticamente detectável ( $p = 0,617$ ) e decorre inteiramente de uma única categoria, *Invention of New Information*, na qual a telemetria acertou 100,0% contra 66,7% do log textual (Tabela 4); nas demais categorias em que ambos foram bem, o desempenho foi igual. A origem dessa divergência, contudo, precisa ser qualificada: no nível das repetições individuais (Tabela 3) os braços estão próximos, 51 de 60 julgamentos corretos na telemetria contra 47 no log textual, de modo que o salto de 66,7% para 100,0% na acurácia por cenário resulta de a moda de apenas dois cenários tombar entre *Invention* e a categoria semanticamente vizinha *Misinterpretation of Tool Output*, ambas falhas do Executor. Uma leitura plausível para a pequena vantagem da telemetria é que o registro estruturado do passo de síntese torna mais explícito que a resposta cita um item ausente da evidência da ferramenta, inclinando algumas repetições adicionais para *Invention*. Por depender de uma só categoria, de dois cenários e de uma margem de uma a duas repetições, e por incidir sobre uma fronteira de alta instabilidade entre as reps, o achado é frágil e requer replicação.

## 5.3 Análise post-hoc dos erros

Além da comparação planejada, inspecionaram-se os cenários em que os braços divergiram, a fim de compreender *por que* o diagnóstico falhou. Essa análise é exploratória e post-hoc.

Em *Invalid Invocation*, o log textual localizou 5 de 6 cenários e a telemetria 4 de 6. A inspeção revela uma ambiguidade entre causa e sintoma: o juiz tende a atribuir a falha ao passo do sintoma (o *SchemaError*, no passo 3) em vez do passo da causa (a chamada malformada, no passo 2). A telemetria, por expor mais detalhes do erro lançado, parece amplificar o passo 3 como discriminador. Em um cenário de avaliação da categoria, 9 das 10 repetições do braço A migraram para o passo 3, e o cenário q10 foi errado por ambos pela mesma razão. Como causa e sintoma são passos adjacentes, o empate sob *Critical Step-index Accuracy*  $\pm 1$  mostra que se trata de ambiguidade fina, não de erro grosseiro.

A categoria *Instruction/Plan Adherence Failure* teve o pior desempenho em ambos os braços (33,3% de categoria; 3 de 6 na localização), sem que a telemetria a atenuasse. A falha é injetada no Coordenador (passo 1) como uma consulta que viola silenciosamente uma restrição da tarefa, **sem** gerar erro ou status anômalo em nenhum passo. Os erros refletem esse caráter silencioso: os 3 cenários em que não conseguiu capturar a falha crítica, em dois deles o juiz não detectou falha alguma (veredito *Inconclusive*, passo 0, em 10 de 10 repetições); em um deles detectou a resposta incorreta, mas a atribuiu ao Executor como *Misinterpretation* (passo 4); e, mesmo quando o passo 1 foi corretamente localizado (q25 e q27), a categoria oscilou entre *Instruction/Plan Adherence Failure* e a categoria vizinha *Intent-Plan Misalignment*. Esse padrão sugere um limite da telemetria operacional: sinais como *spans*, status, erro, duração, *tokens* e chamadas de ferramenta capturam mal falhas de aderência ao plano, pois estas não se manifestam como anomalia operacional, mas como divergência entre o plano e a intenção da tarefa. Diagnosticá-las poderia exigir uma camada de telemetria *semântica* registrando, por exemplo, o plano esperado, o subobjetivo ativo, as restrições da tarefa, a ação esperada *versus* a executada e a justificativa do agente. Essa é a direção mais promissora aberta pelo estudo.

## 6 Conclusão

Este trabalho apresentou uma replicação controlada do AgentRx em um sistema multiagente simulado, com o objetivo de investigar se a forma de representação da trajetória de execução afeta o diagnóstico de falhas. Para isso, compararam-se duas representações da mesma trajetória controlada, sendo elas a telemetria estruturada (braço A) e log textual simplificado (braço B), ambas processadas pelo componente de julgamento do AgentRx, sobre 30 cenários parados com falhas injetadas em cinco categorias.

Os resultados são preliminares e devem ser lidos como evidência descritiva, uma vez que o teste de McNemar não detectou diferença estatisticamente significativa entre os braços em nenhuma das métricas ( $p = 0,617$  para a categoria e  $p = 1,000$  para a localização; Tabela 5). Quanto à **RQ1**, a telemetria estruturada não melhorou a identificação da etapa crítica: o log textual simplificado foi ligeiramente superior na localização exata e na distância média (Tabela 2), com empate sob o intervalo de um passo. Quanto à **RQ2**, observou-se um indício descritivo, porém fraco, de que a telemetria reduz ambiguidades na categorização da causa raiz; a vantagem, contudo, decorreu inteiramente de *Invention of New Information* (Tabela 4) e não foi estatisticamente detectável.

Um padrão informativo emerge da leitura conjunta das duas dimensões: os braços divergiram em *sentidos opostos*, o log textual à frente na localização fina e a telemetria à frente em uma categoria de classificação, e ambas as divergências, pequenas e restritas a categorias específicas, remontam à *mesma* origem: a carga adicional de telemetria presente apenas no braço A. Como evidenciam as Tabelas 4 e 3, esse detalhamento operacional do erro tornou marginalmente mais explícita a natureza fabricada da resposta em *Invention*, mas, ao mesmo tempo, amplificou o passo do sintoma em *Invalid Invocation*, atuando como distrator na localização. O principal achado, portanto, é que a telemetria estruturada, no formato avaliado, não produziu ganho robusto e generalizado sobre a representação textual: conforme a natureza da falha e a dimensão avaliada, o mesmo detalhamento pode tanto auxiliar quanto prejudicar o diagnóstico.

A análise post-hoc dos erros trouxe as contribuições mais informativas do estudo. A categoria *Instruction/Plan Adherence Failure* foi a mais difícil para ambos os braços, e a inspeção dos cenários sugere que falhas de aderência ao plano, por não se manifestarem como anomalia operacional, são mal capturadas pela telemetria operacional comum. Esse achado indica que sinais como *spans*, *status*, *erros*, *duração* e *chamadas de ferramenta* podem ser insuficientes para esse tipo de falha, apontando a necessidade de uma camada de telemetria *semântica*, que registre, o plano esperado, as restrições da tarefa e a ação esperada *versus* a executada.

Como trabalho futuro, pretende-se ampliar o número de cenários e empregar trajetórias mais longas e complexas, capazes de mitigar o efeito-teto observado nas trajetórias curtas. Pretende-se, ainda, avaliar o método sobre *logs* naturais de sistemas multiagentes reais, em contraste com as representações derivadas de uma mesma fonte controlada, e investigar quais sinais específicos de telemetria contribuem para diagnósticos mais precisos.

## 7 Ameaças à Validade

### 7.1 Validade interna

O processo de geração das trajetórias, o adaptador para a IR, a agregação dos julgamentos e a configuração do modelo juiz podem influenciar os resultados. Para reduzir esse risco, a injeção foi *scriptada* e determinística, o evento `fault.injected` e os atributos que revelam a falha foram removidos das trajetórias, o juiz não recebeu o *ground truth* e os dois braços foram derivados do mesmo *trace* bruto.

### 7.2 Validade de construto

Duas limitações merecem destaque. Primeiro, os dois braços são **duas representações de uma mesma fonte controlada**: o log textual simplificado é derivado da telemetria, e não coletado de um sistema real. Portanto, o estudo compara representações alternativas da mesma trajetória, uma com telemetria estruturada e outra textual, e **não** logs naturais heterogêneos contra telemetria estruturada. Segundo, a IR do AgentRx representa cada passo apenas por papel e conteúdo textual; assim, a telemetria do braço A entra como texto, e não como campos estruturados, o que pode subaproveitar seu potencial. Além disso, o *ground truth* adota o ponto de injeção como causa, que pode não coincidir com o passo em que a execução se torna irreversível.

### 7.3 Validade externa

O estudo usa um MAS simulado, tarefas sintéticas, ferramentas *mockadas* e apenas 30 cenários, com trajetórias curtas (cinco passos). As trajetórias curtas produzem efeito-teto nas tolerâncias  $\pm 3$  e  $\pm 5$  (100% em ambos os braços), que deixam de diferenciar os métodos. Os resultados, portanto, não se generalizam diretamente para sistemas reais. Trabalhos futuros devem empregar trajetórias mais longas e complexas, múltiplas chamadas de ferramenta, falhas recuperáveis anteriores à falha principal e erros que emergem por encadeamento.

### 7.4 Validade de conclusão

A amostra é pequena e os testes têm baixo poder estatístico; o teste de McNemar não detectou diferença significativa em nenhuma métrica ( $p = 0,617$  e  $p = 1,000$ ). Os resultados devem ser interpretados como **preliminares e exploratórios**, indicando tendências a confirmar em estudos maiores.

## Referências

- [1] Shraddha Barke, Arnav Goyal, Alind Khare, Avaljot Singh, Suman Nath, and Chetan Bansal. 2026. AgentRx: Diagnosing AI Agent Failures from Execution Trajectories. *arXiv preprint arXiv:2602.02475* (2026).
- [2] Liming Dong, Qinghua Lu, and Liming Zhu. 2024. Agentops: Enabling observability of llm agents. *arXiv preprint arXiv:2411.05285* (2024).
- [3] IBM. 2024. O que é OpenTelemetry? <https://www.ibm.com/br-pt/topics/opentelemetry>. Acessado em: 02 jun. 2026.